

Punto B

La **metodología CRISP-DM** (Cross-Industry Standard Process for Data Mining) es un proceso **estandarizado y estructurado** para llevar a cabo proyectos de análisis de datos y minería de datos de manera eficiente y coherente. Fue desarrollada a finales de los años 90 por varias empresas líderes en la industria con el propósito de ofrecer buenas prácticas para proyectos de análisis y *machine learning* sin estar atada a una herramienta o industria específica.

CRISP-DM divide el proyecto en **seis fases interrelacionadas** que guían desde la identificación del problema hasta la puesta en producción de los resultados. Las fases no son estrictamente lineales; a menudo se regresa a fases previas cuando se aprende algo nuevo durante el análisis.

Las seis fases son:

1. **Comprensión del negocio**
2. **Comprensión de los datos**
3. **Preparación de los datos**
4. **Modelado**
5. **Evaluación**
6. **Despliegue**

En esta investigación nos enfocaremos en **las dos primeras fases**: *Comprensión del negocio* y *Comprensión de los datos*, que son fundamentales para que cualquier proyecto de análisis predictivo tenga sentido y éxito.

Comprensión del negocio

Esta es la **primera fase de CRISP-DM** y es crucial porque define qué se quiere lograr con el análisis, por qué es importante y qué impacto tendrá en la organización. Aquí se traduce un desafío real de negocio a un problema que pueda abordarse con datos. Sin una buena comprensión del negocio, cualquier análisis estadístico o modelo predictivo corre el riesgo de ser inútil o no alineado con las necesidades reales.

Por ejemplo: “Predecir cuáles clientes tienen mayor probabilidad de abandonar el servicio para mejorar la retención.”

Esto permite que el equipo entienda exactamente lo que se busca resolver antes de comenzar el análisis.

Evaluación del contexto

La **evaluación del contexto** es una de las tareas clave dentro de la fase de *Comprensión del negocio* de CRISP-DM. Su propósito es **entender completamente el entorno donde se aplicará el proyecto de análisis predictivo** antes de avanzar a fases técnicas ya que en esta etapa no solo se define qué problema se quiere resolver, sino que se analizan todos los **factores que pueden influir positiva o negativamente** en la implementación del proyecto.

1. Recursos disponibles

Aquí se identifica qué recursos existen y cuáles se necesitarán para realizar el proyecto. Esto incluye: personal (expertos en datos, expertos en negocio, desarrolladores, analistas.), herramientas (hardware, software, herramientas disponibles o necesarias.) o datos (dónde están almacenados, accesibilidad y calidad inicial).

2. Requisitos y restricciones

Se consideran reglas o límites que deben de funcionar el proyecto por ejemplo: normativas de uso de datos (¿Qué restricciones legales o de seguridad existen con los datos?), tiempo disponible o presupuesto (¿Qué nivel de precisión se espera del modelo? o ¿Cuál es la calidad mínima aceptable de los resultados?).

3. Supuestos y riesgos

Se examinan posibles riesgos o suposiciones que puedan afectar el resultado del análisis, y se planifica cómo manejarlos en caso de: Los datos sean de baja calidad, si el modelo no alcanza la precisión esperada o si existen riesgos de operación o de inversión.

4. Costos y Beneficios

Esta parte evalúa si el proyecto vale la pena desde un punto de vista económico o estratégico. Se toman en cuenta por ejemplo: Cuánto costará en recolectar los datos, qué beneficios tendrá la empresa si el modelo funciona bien, cuál es la relación potencial entre inversión y ganancia.

Establecimiento de propósitos técnicos

Una vez que el problema de negocio está claro, se definen los objetivos técnicos concretos que permitirán medir si el análisis fue exitoso. Se define cómo el problema de negocio se traducirá en tareas técnicas que pueden resolver los datos y los modelos predictivos. Esto permite que el equipo de datos comprenda exactamente qué se debe construir y cómo medir si funciona bien, es decir:

1. Objetivos del modelo

Se decide qué tipo de modelo se utilizará según el problema.

Ejemplo: un modelo de *clasificación* para predecir si un cliente va a abandonar o no.

2. Criterios de éxito

Se establecen **medidas cuantificables** para saber si el modelo funciona como se quiere. Ejemplo: “Precisión mínima del 80 %” o “Reducir errores falsos negativos a menos del 15 %”.

3. Requerimientos técnicos

Se identifican las tareas necesarias para desarrollar el modelo (por ejemplo, qué variables se usarán, qué herramientas se necesitarán, etc.).

Compresión de los datos

Después de definir el problema de negocio y los objetivos a resolver, el siguiente paso en un proyecto que usa la metodología CRISP-DM es conocer qué datos se tienen disponibles y si estos realmente ayudan a resolver el problema empresarial. Para esto se pasa a la fase de Comprensión de los datos, que sirve como puente entre *lo que el negocio necesita* y *lo que los datos pueden ofrecer*.

Descripción de los datos

La descripción de los datos es el paso donde se hace un recuento y análisis inicial muy claro de cómo son los datos que se van a usar para resolver el problema de negocio. Esto incluye:

- 1.**Formato de los datos:** Saber si los datos están en tablas, archivos CSV, bases de datos, etc.
- 2.**Identificación de campos o columnas:** Qué representa cada columna (edad, fecha de compra, ingresos).
- 3.**Tipo de cada campo:** Saber si es numérico, texto, fecha, categórico, etc.
- 4.**Significado de los atributos:** Entender qué mide cada variable y qué representa en términos del negocio.
5. **Estructura general:** Número de tablas, cómo se relacionan entre sí y qué tipo de valores contienen.

En resumen, describir los datos significa tener una vista general clara de qué datos tienes y qué puedes hacer con ellos antes de iniciar un análisis profundo.

Establecimiento del volumen de la información

Después de describir cómo son los datos, el Establecimiento del volumen de la información consiste en medir cuánta información hay disponible y si es suficiente para que el análisis predictivo funcione bien. Esto también se hace pensando siempre en el objetivo de negocio: si no hay suficientes datos, el modelo puede no ser confiable para tomar decisiones reales. Esto se hace al:

- 1.**Contar el número de registros:** Saber cuántas filas hay en tus tablas, por ejemplo: cuántos clientes, cuántas ventas, etc.
- 2.**Contar el número de campos o atributos:** Saber cuántas columnas hay por cada registro.
- 3.**Evaluar la cobertura de los datos:** Determinar cuánto cubren los datos: quizá solo hay información de los últimos meses o de algunos clientes, lo cual puede afectar el análisis.
- 4.**Decidir si hay suficientes datos para el modelo:** Un modelo predictivo necesita cierta cantidad de información para aprender patrones. Si el volumen es muy pequeño, el modelo puede no ser confiable.