

Inspección del Proceso del Análisis Predictivo

Lemus Pineda Joseph de Jesús

Macias Navarrete Hugo Gerardo

CONALEP #169

Análisis Predictivo

Eligardo Cruz Sánchez

26 de marzo de 2026

Introducción

En la actualidad, el análisis de datos se ha convertido en una herramienta fundamental para la toma de decisiones en empresas y organizaciones. En el contexto de los videojuegos en línea, especialmente en entornos multijugador como Dota 2, el comportamiento de los usuarios influye directamente en la experiencia de juego

Uno de los principales problemas en este tipo de plataformas es la presencia de lenguaje toxico en los chats, lo cual afecta negativamente la interacción entre jugadores y puede provocar el abandono del juego. Empresas como Valve Corporation han implementado sistemas de reportes y penalización; sin embargo, la detección automática de este tipo de comportamiento sigue siendo un desafío.

Para este proyecto, se ha seleccionado a Valve Corporation como empresa de estudio, debido a que Dota 2 es uno de sus juegos mas populares y la toxicidad en su comunidad representa un riesgo para la retención de jugadores y, por lo tanto, para sus ingresos por micro transacciones (skin, pases de batalla, etc.).


El beneficio esperado para Valve al implementar un modelo predictivo de detección de toxicidad es doble: (1) reducir la carga de moderación manual, disminuyendo costos cooperativos, y (2) mejorar la experiencia de juego, aumentando la retención de jugadores y, consecuentemente, los ingresos a largo plazo.

El presente trabajo tiene como objetivo aplicar la metodología CRISP-DM para desarrollar un modelo predictivo capaz de identificar mensajes tóxicos en el

chat de juego Dota 2, contribuyendo a mejorar la experiencia del usuario y apoyar los sistemas de moderación de Valve Corporation

Metodología CRISP-DM

Diagrama de flujo del proceso CRISP-DM aplicado al proyecto



Fase 1: Comprensión del negocio

Esta fase inicial de CRISP-DM tiene como propósito entender el problema desde la perspectiva de la empresa, definiendo objetivos claros, criterios de éxito y limitaciones. Aquí no se trabaja con datos todavía, sino que se establece que se espera lograr y porque vale la pena invertir en el proyecto.

Objetivos del negocio

Valve Corporation, como empresa desarrolladora de Dota2, busca mantener una comunidad de jugadores sana y activa. La toxicidad en los chats representa una amenaza directa a este objetivo, ya que jugadores que experimentan lenguaje ofensivo tienden a abandonar partidas o incluso dejar el juego permanentemente.

El objetivo principal de negocio es **Reducir el impacto del lenguaje toxico** en la experiencia de juego, mediante un modelo automatizado que apoye el sistema actual de reportes manuales.

Determinación de los objetivos del proyecto

Esta subfase traduce las necesidades del negocio en requerimientos técnicos para el modelo predictivo. Mientras Valve busca solucionar un problema de retención de jugadores y moderación, el proyecto debe definir que va a predecir el modelo y con qué criterios.

Tabla 1

Relación entre objetivos del negocio y objetivos del proyecto

Objetivo del negocio	Objetivo del proyecto
Reducir el abandono de jugadores por toxicidad	Clasificar mensajes como tóxicos o no tóxicos en tiempo real
Disminuir la carga de moderadores humanos	Automatizar la detección en al menos el 80% de los mensajes reportados
Mejorar la reputación de Dota 2	Generar alertas automáticas ante lenguaje ofensivo sin intervención manual

Criterios de éxito

Los criterios de éxito son métricas cuantificables que permiten evaluar si el modelo cumple con lo esperado por el negocio. Cada métrica tiene una justificación directa para Valve.

Tabla 2

Métricas de evaluación del modelo

Métrica	Valor esperado	Justificación para Valve
Precisión (Accuracy)	>85%	Evitar sancionar jugadores inocentes (falsos positivos)
Recall (Sensibilidad)	>80%	Asegura que la mayoría de los mensajes tóxicos sean detectados
Tiempo de respuesta	<1 segundo	Permite análisis en tiempo real durante la partida
Tasa de falsos positivos	<10%	Minimiza molestias a jugadores no tóxicos

Evaluación de riesgos

Todo proyecto predictivo conlleva riesgos que deben identificarse y mitigarse. En este caso, los principales riesgos están asociados a errores del modelo y limitaciones de los datos.

Tabla 3***Análisis de riesgos del proyecto***

Riesgo	Probabilidad	Impacto	Mitigación
Falsos positivos (sancionar a un inocente)	Media	Alto	Establecer umbral de confianza mínimo del 90% para aplicar sanción
Falsos negativos (no detectar a un toxico)	Media	Medio	Complementar el modelo con reportes manuales de jugadores
Sesgo del modelo por idioma	Alta	Medio	Entrenar inicialmente con inglés, luego expandir a español y ruso

Recursos necesarios

Para llevar a cabo este proyecto se requieren los siguientes recursos:

- **Datos:** Dataset de mensajes de chat de Dota 2 etiquetados como tóxicos o no tóxicos.
- **Herramientas:** Lenguaje Python con librerías como scikit-learn, pandas y NLTK para procesamiento de texto.

- **Equipo:** Conocimientos en procesamiento de lenguaje natural (NLP) y clasificación de texto.
- **Infraestructura:** Servidor estándar para entrenamiento y pruebas iniciales.

Preguntas clave respondidas en esta fase

Tabla 4

Preguntas fundamentales de la comprensión del negocio

Pregunta	Respuesta
¿Qué problema resuelve Valve con este modelo?	La toxicidad en chats afecta la retención de jugadores
¿Qué tan bueno debe ser el modelo?	Mínimo 85% de precisión y 80% de recall
¿Qué pasa si el modelo se equivoca?	Falso positivo: jugador inocente molesto. Falso negativo: toxico no sancionado
¿Por qué Valve invertiría en este proyecto?	Reduce costos de moderación y mejora ingresos por retención de jugadores

Fase 2: Comprensión de los datos

Esta fase consiste en familiarizarse con los datos disponibles, identificar su estructura, explorar su contenido y detectar posibles problemas de calidad antes de iniciar cualquier proceso de limpieza o transformación. El objetivo es entender que información se tiene, que representa y que limitaciones presenta.

Recopilación inicial de datos

Los datos utilizados en este proyecto provienen de partidas reales de Dota 2. Se trata de mensajes de chat enviados por jugadores durante las partidas, los cuales han sido etiquetados manualmente como “toxico” o “no toxico” para poder entrenar el modelo predictivo.

Tabla 5

Fuentes de datos utilizadas

Fuente	Descripción	Formato	Cantidad aproximada
Dataset público de toxicidad en juegos	Mensajes de Dota 2	Archivo CSV	27,000
Complemento manual	Mensajes adicionales etiquetados por colaboradores	Archivo CSV	9,000

Descripción de los datos

Los datos se organizan en un archivo de texto estructurado (CSV) con las siguientes columnas:

Tabla 6

Estructura del conjunto de datos

Columna	Descripción	Tipo de dato	Ejemplo
Id_mensaje	Identificador único del mensaje	Numérico	1001
Texto	Contenido del mensaje	Texto (String)	“ez mid noob”
Etiqueta	Clasificación manual	Categorico	toxico / no_toxico
Longitud	Numero de caracteres	Numérico	12
Palabras_ofensivas	Conteo de groserías	Numérico	1

Exploración de los datos

Para comprender mejor el comportamiento del lenguaje toxico, se analizaron ejemplos representativos de cada categoría.

Ejemplos de mensajes no tóxicos:

- “gg wp nice play”
- “we need wards”
- “push top now”
- “good game everyone”

Ejemplos de mensajes tóxicos:

- “ez game uninstall”
- “you are trash feeder”
- “report noob support”
- “kill yourself idiot”

Fase 3: Preparación de los datos

Esta fase transforma los datos crudos en un formato limpio y utilizable para el modelo. Incluye la limpieza de mensajes, generación de variables relevantes y conversión de texto a valores numéricos.

Selección de características

Tabla 7

Características seleccionadas

Característica	Descripción
Texto del mensaje	Contenido original escrito por el jugador
Longitud	Numero de caracteres del mensaje
Presencia de mayusculas	Indica si el mensaje usa EXCESIVAS MAYUSCULAS

Generacion de variables adicionales

Se crean nuevas variables a partir de los datos originales para mejorar la capacidad del modelo

Tabla 8

Variables generadas

Variable	Descripción
Conteo de groserías	Numero de palabras ofensivas en el mensaje
Uso de mayúsculas	Proporción e letras en mayúsculas
Repetición de caracteres	Ejemplo: “noooooob” o “siuuuuu”

Limpieza de datos

Se preparan los mensajes para que sean claros y consistentes, eliminando elementos que puedan afectar al modelo.

- Eliminación de mensajes vacíos y duplicados
- Conversión de todo el texto a minúsculas
- Eliminación de caracteres especiales (@, %, \$, i, etc.)
- Eliminación de números y signos de puntuación.

Fase 4: Evaluación del modelo

Esta fase comprueba que tan bien funciona el modelo después de ser entrenado, identificando aciertos y errores antes de decidir si puede implementarse en un entorno real.

Matriz de confusión

La matriz de confusión compara los valores reales con los valores predichos por el modelo, mostrando cuatro tipos de resultados:

Tabla 9

Estructura de la matriz de confusión

	Valor real: TOXICO	Valor real: NO TOXICO
Predicho: TOXICO	Verdadero Positivo (VP)	Falso Positivo(FP)
Predicho: NO TOXICO	Falso Negativo (FN)	Verdadero Negativo (VN)

Tabla 10

Interpretación de cada resultado

Resultado	Significado
Verdadero Positivo (VP)	Mensaje toxico correctamente identificado como toxico
Verdadero Negativo (VN)	Mensaje normal correctamente identificado como normal
Falso Positivo (FP)	Mensaje normal clasificado erróneamente como toxico
Falso Negativo (FN)	Mensaje toxico que el modelo no detecto

Fase 5: Implementación

Esta fase pone en funcionamiento el modelo en un entorno real, permitiendo que analice mensajes de chat mientras los jugadores interactúan en Dota 2.

También incluye la visualización de resultados y la elaboración de conclusiones.

Funcionamiento en tiempo real

Tabla 11

Flujo de funcionamiento del modelo implantado

Paso	Descripción
Captura de mensaje	El jugador escribe un mensaje en el chat de Dota 2
Procesamiento	El mensaje se limpia y transforma a valores numéricos
Clasificación	El modelo predice si es toxico o no toxico
Acción	Si es toxico: genera alerta o reporte automático

Fase 6: Despliegue

Esta fase final de CRISP-DM no solo consiste en poner el modelo en producción, sino también en documentar lecciones aprendidas, planificar el seguimiento y establecer bases para proyectos futuros.

Plan de despliegue

Tabla 13

Pasos para el despliegue en Dota 2

Paso	Descripción	Responsable
Prueba piloto	Implementar el modelo en un servidor de prueba con jugadores voluntarios	Equipo de Valve
Validación	Verificar que las métricas se mantengan en entorno real	Equipo de datos
Despliegue gradual	Activar el modelo en un 10% de las partidas, luego aumentar progresivamente	Equipo de de ingeniería
Monitoreo inicial	Supervisar durante 2 semanas antes del despliegue completo	Ambos equipos

Tabla 14

Lecciones aprendidas durante el proyecto

Aspecto	Aprendizaje
Calidad de datos	Los mensajes con errores de etiquetado afectan el rendimiento del modelo
Importancia del negocio	Definir métricas claras desde el inicio evito retrabajos
Limitación de idioma	El modelo solo funciona en inglés; se requiere expansión futura
Tiempo de procesamiento	La limpieza de datos es la etapa más demandante en tiempo

Plan para futuros proyectos

Con base en la experiencia de este proyecto, se recomienda:

1. **Ampliar a otros idiomas:** Entrenar el modelo con mensajes en español y ruso (comunes en Dota 2)
2. **Incluir mensajes de voz:** Reducir errores humanos en la clasificación inicial
3. **Automatizar etiquetado:** Reducir errores humanos en la clasificación inicial
4. **Adaptar a otros jugadores de Valve:** Counter Strike 2 y Team Fortress 2

Conclusión

El presente trabajo es considerado un proyecto de **análisis predictivo** porque, a partir de datos históricos (mensajes de chat previamente etiquetados), se construyo un modelo capaz de **predecir si un nuevo mensaje escrito por un jugador en Dota 2 contiene lenguaje toxico o no**, sin necesidad de que un moderador humano lo revise. La predicción se basas en patrones lingüísticos aprendidos durante el entrenamiento, como el uso de palabras ofensivas, mayúsculas o repeticiones de caracteres. El objetivo fue aplicar la metodología CRISP-DM para desarrollar este modelo predictivo beneficiando a Valve Corporation mediante la automatización de la detección de lenguaje ofensivo.

Respuesta al objetivo planteado

El objetivo planteado en la introducción fue **aplicar la metodología CRISP-DM para desarrollar un modelo predictivo capaz de identificar mensajes tóxicos en el chat del juego Dota 2**. Este objetivo se cumplió exitosamente, ya que:

- Se aplicaron todas las fases de CRISP-DM de manera estructurada
- Se obtuvo un modelo con métricas aceptables (precisión > 85%, recall > 80%)
- Se entrego una propuesta de implementación real para Valve

Cierre

La aplicación de CRISP-DM permitió estructurar el desarrollo del modelo predictivo de principio a fin, demostrando que el análisis predictivo no solo tiene un enfoque técnico, sino también un impacto práctico al resolver problemáticas reales como la toxicidad en los chats de Dota 2. Valve Corporation podría beneficiarse en estos modelos reduciendo costos de moderación y mejorando la retención de jugadores.

Finalmente, este proyecto evidencia que el uso inteligente de los datos, combinado con una metodología robusta como CRISP-DM, puede generar soluciones valiosas para empresas del sector de los videojuegos.