

Punto A

Borrador hecho por Hugo

La metodología CRISP-DM (Cross Industry Standard Process for Data Mining) es un modelo estándar utilizado para desarrollar proyectos de minería de datos y análisis predictivo. Está compuesta por seis fases principales: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación e implantación (despliegue) del modelo.

A continuación, se muestra el proceso desde la preparación de datos hasta la implantación, incluyendo las actividades que mencionaste.

Proceso de análisis predictivo con CRISP-DM

1. Preparación de los datos

La preparación de los datos es la etapa del proceso de análisis predictivo donde los datos originales se organizan y se preparan para poder analizarlos correctamente. En esta fase se seleccionan los datos relevantes, se corrigen errores, se eliminan inconsistencias y se transforman los datos para que puedan ser utilizados por los algoritmos de análisis. El objetivo principal es obtener un conjunto de datos limpio, organizado y listo para el modelado, ya que la calidad de los resultados depende en gran medida de la calidad de los datos utilizados.

Selección de características: La selección de características consiste en elegir cuáles datos o variables son realmente útiles para hacer el análisis o construir un modelo predictivo. En un conjunto de datos suele haber mucha información, pero no toda es relevante, por lo que se eliminan las variables que no aportan valor o que pueden causar ruido en el análisis.

Generación de variables adicionales: La generación de variables adicionales significa crear nuevos datos a partir de los datos que ya existen para mejorar el análisis. Esto se hace combinando, transformando o calculando información que puede ayudar a encontrar patrones más claros.

Limpieza de datos: La limpieza de datos consiste en revisar los datos para corregir errores o problemas antes de analizarlos. En este proceso se eliminan registros duplicados, se corrigen datos incorrectos, se manejan valores faltantes y se detectan valores extraños que podrían afectar los resultados. El objetivo es que los datos sean confiables y de buena calidad, ya que, si los datos están mal, el modelo predictivo también dará resultados incorrectos.

Cambios de formato: Los cambios de formato consisten en transformar los datos para que puedan ser utilizados correctamente por las herramientas o algoritmos de análisis. Esto puede incluir convertir textos a números, organizar columnas, cambiar el tipo de dato o estandarizar formatos como fechas o unidades. Aunque estos cambios no alteran el significado de los datos, sí facilitan que el sistema pueda procesarlos correctamente durante el análisis.

Integración de diferentes orígenes de datos: La integración de diferentes orígenes de datos significa combinar información que proviene de distintas fuentes para crear un solo conjunto de datos completo.

2. Modelado de datos

El modelado de datos es la etapa en la que se aplican técnicas de minería de datos o algoritmos de aprendizaje automático al conjunto de datos preparado para encontrar patrones y realizar predicciones. En esta fase se seleccionan los métodos o algoritmos más adecuados, se entrenan con los datos disponibles y se ajustan sus parámetros para obtener el mejor rendimiento posible. El objetivo del modelado es construir un modelo capaz de analizar la información y generar predicciones o resultados útiles a partir de los datos.

Técnicas de minería (algoritmos predictivos): Las técnicas de minería de datos son métodos o algoritmos que se utilizan para encontrar patrones y hacer predicciones a partir de los datos. Estos algoritmos analizan la información disponible para descubrir relaciones, tendencias o comportamientos que no son visibles a simple vista.

Selección de técnicas de modelado: La selección de técnicas de modelado consiste en elegir qué tipo de algoritmo o método se utilizará para construir el modelo predictivo. Esta decisión depende del tipo de problema que se quiere resolver, de la cantidad y calidad de los datos disponibles y del conocimiento que se tenga sobre cada técnica. Elegir correctamente la técnica es importante porque influye directamente en la precisión y utilidad del modelo.

Modelado del conjunto de datos: El modelado del conjunto de datos es el proceso donde se aplican los algoritmos seleccionados a los datos preparados para crear un modelo predictivo. En esta etapa el sistema aprende a partir de los datos históricos para identificar patrones y poder hacer predicciones sobre datos nuevos. También se realizan pruebas y ajustes al modelo para mejorar su rendimiento y asegurar que funcione correctamente.